

# Compressive Sensing for Background Subtraction

Amine Hammami et Charles Dognin

ENSAE Paritech

# Outline

- 1 Introduction
- 2 The compressive Sensing Theory
- 3 CS for Background Subtraction
- 4 Experiments

# The sparse representation

Soit  $X$  une image de taille  $N_1 \times N_2$  et  $x$  un vecteur obtenu à partir de  $X$  de taille  $N \times 1$  ( $N = N_1 N_2$ ).

Supposons qu'il existe  $\Psi = [\psi_1, \dots, \psi_N]$  une base fournissant la représentation  $K$  sparse de  $x$ :

$$x = \sum_{n=1}^N \theta(n) \psi_n = \sum_{l=1}^K \theta(n_l) \psi_{n_l} = \Psi \Theta$$

Une image est  $K$  sparse si  $\|\theta\|_0 = K$  où  $l_0$  compte le nombre d'éléments non nuls.

# Random/Incoherent Projections

Il est impossible de mesurer les valeurs de  $K$  les plus larges.  
La projection de  $x$  sur un ensemble de projecteurs linéaires  
 $\Phi = [\phi'_1, \dots, \phi'_M]'$  avec  $(M < N)$  est elle mesurable:

$$y = \Phi x = \Phi \Psi \theta$$

La théorie du Compressed Sensing repose sur deux hypothèses:

- les deux bases  $\Phi$  et  $\Psi$  doivent être incohérentes
- $M$  supérieur à  $\mathcal{O}(K \log(\frac{N}{K}))$

# Signal Recovery via $l_1$ Optimization

l'optimisation  $l_1$  peut être utilisée pour la reconstruction du signal:

$$\hat{\theta} = \operatorname{argmin} \|\theta\|_1 \text{ sachant que } y = \Phi\Psi\theta$$

Dans ce papier, la méthode utilisée est Basis Pursuit Denoising:

$$\hat{\theta} = \operatorname{argmin} \|\theta\|_1 + \frac{1}{2}\beta\|y - \Phi\Psi\theta\|_2^2$$

where  $0 < \beta < \infty$

# Notation

But: Retrouver la localisation, la forme et l'apparence d'un nouvel objet en utilisant des arrières plans d'entraînement.

- $x_b$  Image arrière plan
- $x_t$  Image test
- $x_d$  Image soustraite

L'image soustraite est définie comme la soustraction entre l'image arrière plan et l'image test.

Le support de  $x_d$  est  $\mathcal{S}_d = \{n | n = 1, \dots, N; |x_d(n)| \neq 0\}$

# Sparsity of Background Subtracted Images

La sparsité des images réelles est définie comme

$$K_{\text{scene}} = K_b = K_t = (\lambda_0 \log N + \lambda_1)N \text{ où } (\lambda_0, \lambda_1) \in \mathbb{R}^2.$$

La sparsité de  $x_d$  est  $K_d = (\lambda_0 \log P + \lambda_1)P$  où  $P = |\mathcal{S}_d|$ .

Le nombre d'échantillon compressé:

$$M_{\text{scene}} = M_b = M_t \approx K_{\text{scene}} \log\left(\frac{N}{K_{\text{scene}}}\right) < M_d \approx K_d \log\left(\frac{N}{K_d}\right)$$

# The Background Constraint

Supposons un échantillon de mesures compressées

$y_{bi}(M \times 1, i = 1, \dots, B)$  extrait d'un ensemble d'images arrière plan  $x_{bi}$  qui suit une loi i.i.d  $\mathcal{N}(y_b, \sigma^2 I)$ .

Nous modélisons de plus  $y_d = y_t - y_b \sim \mathcal{N}(\mu_d, \sigma^2 I)(M \times 1)$ .

Nous introduisons la distance  $l_2$  afin d'être robuste au bruit:

$$\|y_{bi} - y_b\|_2^2 = \sigma^2 \sum_{n=1}^M \left( \frac{y_{bi}(n) - y_b(n)}{\sigma} \right)^2$$

Quand  $M > 30$ , l'application du théorème central limite donne que  $\|y_{bi} - y_b\|_2^2 \sim \mathcal{N}(M\sigma^2, 2M\sigma^4)$ .



En ayant une image test avec un nouvel objet à détecter, la distribution devient:

$$\|y_t - y_b\|_2^2 \sim \mathcal{N}(M\sigma^2 + \|\mu_d\|_2^2, 2M\sigma^4 + 4\sigma^2\|\mu_d\|_2^2).$$

Sachant que:

- $\frac{1}{M} \ll 1$
- Si  $u \ll 1$  on a  $1 + u \approx e^u$
- $\mathcal{N}(M\sigma^2, 2M\sigma^4) \approx M\sigma^2 \exp\{\sqrt{\frac{2}{M}}\mathcal{N}(0, 1)\}$

nous avons finalement:

$$\log \|y_{bi} - y_b\|_2^2 \sim \mathcal{N}(\mu_{bg}, \sigma_{bg}^2)$$

## Object Detector Based on CS

Utilité d'un test pour voir la différence entre une image arrière plan et une image test.

Nous introduisons la distance  $l_2$  entre  $y_t$  et  $y_b$  que nous approximons:

$$\log ||y_t - y_b||_2^2 \sim \mathcal{N}(\mu_t, \sigma_t^2)$$

Si  $|\log ||y_t - y_b||_2^2 - \mu_{bg}| \geq c\sigma_{bg}$ , alors un nouvel objet est détecté dans l'image test.

# Foreground Reconstruction

Nous avons utilisé l'algorithme de Basis Pursuit Denoising:

$$\hat{\Theta} = \underset{\Theta}{\operatorname{argmin}} \|\Theta\|_1 + \frac{1}{2} \beta \|y - \Phi \Psi \Theta\|_2^2$$

où  $0 < \beta < \infty$  et l'algorithme total variation optimization:

$$\underset{\theta}{\operatorname{minimiser}} \|\theta\|_{\text{TV}} = \|\nabla \theta\|_1 \text{ tels que } \|\Psi \Theta - y\|_2 \leq \epsilon$$

$$\text{où } ((\nabla \theta)_i)_j = \theta_{i+e_j} - \theta_i$$

## Adaptation of the Background Constraint

Deux types de changement:

- drifts comme les illuminations
  - shifts des changements majeurs et brusques
- Les shifts sont très difficiles à gérer.
- Créer un algorithme robuste aux drifts  $\Rightarrow y_b$  doit être continuellement mis à jour et doit faire la distinction entre un changement dans l'arrière plan et un nouvel objet à détecter:

$$y_{ma}^{\{j+1\}} = \gamma y_t^{\{j\}} + (1 - \gamma) y_{ma}^{\{j\}}$$
$$y_b^{\{j+1\}} = \alpha (y_t^{\{j\}} - \hat{y}_e^{\{j\}}) + (1 - \alpha) y_b^{\{j+1\}}$$

# Background subtraction with an SPC




Figure 1: First Experiment's results

L'innovation est reconstruite avec l'algorithme même avec un taux inférieur à 1%

# Adaptation to Illumination Changes



Figure 2: Adaptation to Illumination Changes

La deuxième règle de mise à jour performe mieux que la première.




Figure 3: Silhouettes vs. Difference Images

Ils utilisent une configuration pour une reconstruction 3D en utilisant des mesures de compression.

Les figures de gauche représentent de gauche à droite la vérité de terrain et l'image 3D soustraite en arrière-plan en utilisant CS  $\Rightarrow$  résultat pas très satisfaisant: ça intègre des éléments de l'arrière-plan.